Nama : Jos Hwen Sim
NIM : 2802451655

Bagian A :

1a.Slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout"
Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.

- Pada BatchNorm (Slide 6-8), aktivasi dinormalisasi memakai mean dan variance dari mini-batch yang sedang diproses. Karena isi mini-batch diacak di setiap iterasi, statistik ini ikut berubah. Akibatnya, sampel yang sama bisa menghasilkan nilai ternormalisasi yang sedikit berbeda, tergantung dari sampel lain dalam batch-nya. Perbedaan ini bekerja seperti noise pada aktivasi, sehingga model sulit menghafal sampel tertentu.Efeknya ringan karena hanya gangguan statistik, tidak seperti Dropout yang mematikan neuron.

1b.**Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.**

- Asumsi “tidak perlu Dropout” tidak berlaku kalau batch size terlalu kecil, karena mean dan variance menjadi tidak representatif dan pelatihan tidak stabil. Dropout juga masih berguna pada dataset kecil dengan model besar yang tetap overfit. Selain itu, memasang Dropout tepat sebelum BatchNorm bisa membuat variance berbeda antara mode train dan test

2a.Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)
Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?

- Secara teori model yang lebih dalam minimal bisa menyamai model dangkal karena lapisan tambahan cukup meniru identity mapping. Namun pada plain CNN (Slide 10), optimizer kesulitan menemukan bobot yang membuat tumpukan lapisan nonlinear berperilaku seperti identitas yang membuat akurasi training justru turun. Jadi masalahnya ada pada optimisasi bukan pada kapasitas model

2b.**Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).**

- Pada blok residual (Slide 11-12), keluarannya $y = F(x) + x$. Lapisan cukup membuat $F(x)$ mendekati nol untuk menghasilkan identitas dan itu jauh lebih mudah. Saat backpropagation turunannya menjadi $\partial y/\partial x = \partial F/\partial x + 1$. Suku +1 memberi gradien

jalur langsung ke lapisan awal tanpa dikalikan bobot berkali-kali.Pada plain CNN, gradien adalah perkalian berantai yang mudah mengecil.Dengan skip connection, gradien tetap terjaga walaupun F(x) kecil, sehingga jaringan dalam tetap bisa dilatih.

3.Feature Extraction vs. Fine-Tuning (Slide 14–16)
**Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan FineTuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi: **

- **Jumlah parameter yang diperbarui (trainable parameters).**
- **Kebutuhan volume data latih.**
- **Beban komputasi dan memori per epoch.**
- **Risiko rusaknya fitur representasi bawaan (destructive gradient updates). Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.**

- Pada feature extraction (Slide 16) backbone dibekukan dan hanya head baru yang dilatih. Di ResNet-18 itu hanya 5.130 parameter sedangkan fine-tuning layer4 + fc memperbarui sekitar 8,4 juta parameter. Karena itu feature extraction cukup dengan data sedikit, lebih ringan dari sisi komputasi dan memori per epoch, dan fitur bawaan aman karena bobotnya tidak berubah. Fine-tuning butuh data lebih banyak dan memori lebih besar. Ia juga berisiko destructive gradient updates: head baru masih acak sehingga gradien awalnya besar dan bisa merusak bobot backbone kalau learning rate terlalu tinggi.Kriterianya adalah pilih feature extraction kalau data sangat terbatas dan domainnya mirip ImageNet (Slide 15, 29). Pilih fine-tuning bertahap dengan learning rate kecil kalau data lebih banyak atau domainnya berbeda

4a.Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)
Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.

- Augmentasi (Slide 20-22) hanya dipakai pada train set karena tujuannya memberi variasi tambahan agar model tidak menghafal. Validation dan test set berfungsi mengukur performa pada data nyata kalau diaugmentasi secara acak, hasil evaluasi berubah-ubah setiap dijalankan, dan kita tidak bisa membedakan apakah model memang buruk atau gambarnya kebetulan jelek. Karena itu keduanya hanya diberi transformasi deterministik seperti resize, center crop, dan normalisasi. Augmentasi juga harus dilakukan setelah data dibagi agar tidak terjadi data leakage.

4b.**Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.**

- Contoh transformasi yang tidak layak adalah hue shift besar pada Color Jitter. Warna bulu adalah ciri utama pembeda banyak ras, misalnya kucing oren dan kucing

abu-abu. Kalau warnanya diubah drastis, citra tidak lagi sesuai dengan label aslinya, sehingga melanggar invariansi semantik label.

5a.Mitigasi Catastrophic Forgetting (Slide 28–29) Slide 28 mengingatkan potensi terjadinya catastrophic forgetting apabila proses adaptasi model berlangsung terlalu agresif.
Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.

- Catastrophic forgetting (Slide 28) terjadi saat bobot pretrained berubah terlalu jauh dan terlalu cepat. Head baru diinisialisasi acak, jadi loss dan gradien di awal pelatihan besar. Gradien ini ikut mengalir ke backbone. Bila learning rate tinggi, bobot yang menyimpan fitur umum seperti tepi dan tekstur bergeser jauh dari hasil pelatihan ImageNet. Fitur bawaan pun hilang dan model mendekati pelatihan dari nol pada data yang kecil

5b.**Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.**

- Strategi pertama differential learning rate dimana backbone diberi LR kecil (misalnya aja 1e-4) dan head LR lebih besar (misalnya aja 1e-3). Lapisan pretrained sudah hampir benar sehingga cukup digeser sedikit saja sedangkan head perlu belajar dari nol. Strategi kedua adalah gradual unfreezing (Slide 16) dimana head dilatih dulu sampai stabil baru layer4 dibuka, sehingga gradien yang masuk ke backbone sudah kecil dan lebih bermakna