# Laporan Hasil Eksperimen

Tugas 05 – Bagian C: Laporan dan Analisis Transfer Learning

**Nama: Jos Hwen Sim | NIM: 2802451655**

*Oxford-IIIT Pet (10 kelas) · ResNet-18 dan EfficientNet-B0 · seed = 42*

## C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

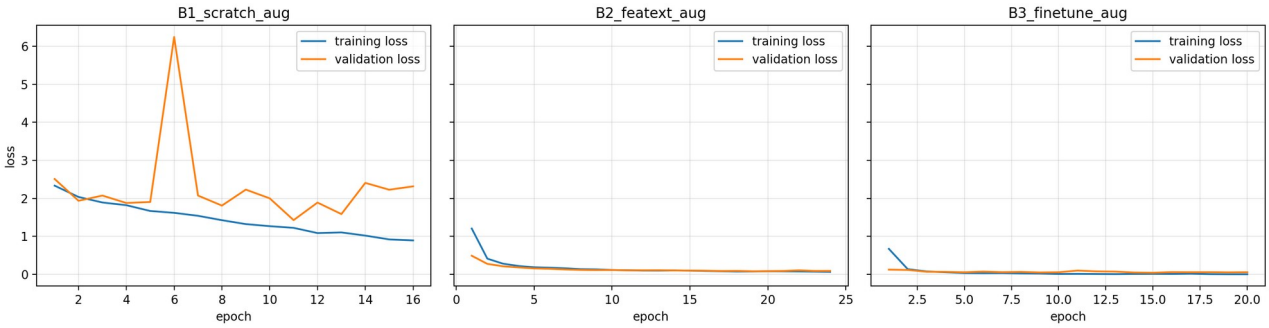
Pada eksperimen ini dibandingkan lima kondisi menggunakan 10 kelas dari dataset Oxford-IIIT Pet, yaitu pelatihan dari nol (B1), feature extraction (B2), fine-tuning layer4 (B3), uji augmentasi (B4, dijalankan pada B3), dan EfficientNet-B0 sebagai arsitektur pembanding (B5). Semua kondisi memakai pengaturan yang sama, yaitu batch size 32, AdamW dengan weight decay 1e-2, early stopping patience 5, dan pembagian data 1.397/300/300 untuk train/val/test. Semua angka diambil dari berkas *results_summary.csv*.

**Tabel 1.** Ringkasan eksperimen B1–B5

| Kode | Strategi | Trainable params | Learning rate | Epoch (terbaik / jalan) | Waktu (s) | Akurasi val | Macro F1 test |
|---|---|---|---|---|---|---|---|
| B1 | From scratch + aug | 11.181.642 (100%) | 1e-3 (semua) | 11 / 16 | 256,9 | 0,5200 | 0,5045 |
| B2 | Feature extraction + aug | 5.130 (0,05%) | fc: 1e-3 | 19 / 24 | 322,9 | 0,9700 | 0,9699 |
| B3 | Fine-tuning layer4 + fc + aug | 8.398.858 (75,1%) | layer4: 1e-4; fc: 1e-3 | 15 / 20 | 270,2 | 0,9833 | 0,9602 |
| B4 | B3 tanpa augmentasi | 8.398.858 (75,1%) | layer4: 1e-4; fc: 1e-3 | 19 / 24 | 223,0 | 0,9900 | 0,9599 |
| B5 | EfficientNet-B0 + aug (features[7:9] + classifier) | 1.142.202 (28,4% dari 4.020.358) | features[7:9]: 1e-4; classifier: 1e-3 | 11 / 16 | 230,5 | 0,9967 | 0,9767 |

**Tabel 2.** Indikator generalisasi (akurasi train diukur tanpa augmentasi pada checkpoint terbaik)

| Kode | Acc. train | Acc. val | Gap train–val | Acc. test | Test loss | Detik/epoch |
|---|---|---|---|---|---|---|
| B1 | 0,6149 | 0,5200 | 0,0949 | 0,5200 | 1,2987 | 16,05 |
| B2 | 0,9843 | 0,9700 | 0,0143 | 0,9700 | 0,1225 | 13,45 |
| B3 | 0,9993 | 0,9833 | 0,0160 | 0,9600 | 0,1528 | 13,51 |
| B4 | 1,0000 | 0,9900 | 0,0100 | 0,9600 | 0,1198 | 9,29 |
| B5 | 0,9993 | 0,9967 | 0,0026 | 0,9767 | 0,0756 | 14,40 |




**Gambar 1.** Kurva training loss vs. validation loss untuk B1, B2, dan B3

Pada B1, *training loss* turun stabil dari 2,33 menjadi 0,89, tetapi *validation loss* naik turun di kisaran 1,43 sampai 2,52 dan sempat melonjak sampai 6,25 pada epoch 6, tanpa tren menurun yang jelas. Pada B2, kedua kurva turun halus dan saling berhimpit setelah sekitar epoch 8. Pada B3, *validation loss* sudah rendah sejak epoch pertama (0,126) dan *training loss* hampir nol (0,012 pada epoch 10). Pada B2 dan B3, *validation loss* terlihat lebih rendah dari *training loss* di epoch awal. Hal ini terjadi karena *training loss* dihitung pada data beraugmentasi saat model masih berubah, sedangkan *validation loss* dihitung pada data bersih di akhir epoch.

## C2. Pembahasan Analisis Komparatif

**1. Disparitas B1 dengan B2 dan B3 (Slide 10–12, 16)**

Macro F1 B1 hanya 0,5045 sedangkan B2 dan B3 mencapai 0,9699 dan 0,9602, selisihnya sekitar 46 poin. Residual connection membuat ResNet-18 bisa dioptimasi tanpa degradasi, dan hal ini terlihat dari *training loss* B1 yang turun terus. Tetapi skip connection tidak menambah informasi baru. Dengan 11,18 juta parameter dan hanya 1.397 citra latih (sekitar 8.000 parameter per citra), B1 harus belajar fitur visual dari awal, dan setelah 16 epoch akurasi train bersihnya baru 61,5%. Karena itu B1 lebih cocok disebut *underfitting* dan tidak stabil daripada *overfitting*. Celah train–val B1 hanya 9,5 poin, jauh lebih kecil dibandingkan selisihnya dengan B2/B3, jadi kekurangan B1 terutama ada pada kualitas representasi yang dipelajari. Sebaliknya, B2 dengan hanya 5.130 parameter terlatih sudah mencapai 97%. Ini menunjukkan fitur ImageNet *linearly separable* untuk ras hewan pada dataset ini, dan wajar karena ImageNet sendiri banyak memuat kelas anjing dan beberapa kelas kucing. B1 juga dihentikan *early stopping* ketika *training loss* masih turun, sehingga hasilnya kemungkinan masih batas bawah yang pesimistis.

**2. Trade-off performa vs. stabilitas: feature extraction dan fine-tuning**

Pada data validasi B3 lebih unggul, dengan akurasi 0,9833 dibanding 0,9700 dan val loss 0,0439 dibanding 0,0832. B3 juga konvergen lebih cepat, terlihat dari akurasi val epoch 1 sebesar 0,957 dibanding 0,920 pada B2. Namun pada test set B2 justru sedikit lebih baik (F1 0,9699 vs 0,9602; test loss 0,1225 vs 0,1528). Selisih 0,97 dan 0,96 hanya setara 3 dari 300 citra dan masih berada dalam galat sampling (±2 poin pada tingkat kepercayaan 95%), sehingga **keduanya tidak dapat dibedakan secara meyakinkan**. B3 melatih 1.637 kali lebih banyak parameter dan akurasi trainnya mencapai 99,93% (B2: 98,43%). Test loss B3 yang lebih tinggi juga menunjukkan prediksi salah yang lebih percaya diri. Tidak terlihat tanda *catastrophic forgetting* karena val loss B3 sudah rendah sejak epoch 1, yang sesuai dengan langkah mitigasi yang dipakai, yaitu hanya layer4 yang dibuka, learning rate 1e-4 (10× lebih kecil dari head), dan BatchNorm pada blok beku tetap di mode eval. Meski begitu, retensi pengetahuan ImageNet tidak diukur secara langsung. Jadi untuk data terbatas dengan domain yang dekat dengan ImageNet, feature extraction sudah cukup, sedangkan fine-tuning hanya menambah kapasitas tanpa keuntungan generalisasi yang terbukti.

**3. Peran augmentasi (B4; Slide 20)**

Dari perbandingan B3 dengan dan tanpa augmentasi, hipotesis bahwa augmentasi meredam overfitting **tidak didukung** oleh data kami. Celah akurasi train–val adalah 0,0160 (dengan aug) dan 0,0100 (tanpa aug), celah loss 0,0400 dan 0,0365, akurasi test sama-sama 0,96, dan Macro F1 test 0,9602 dan 0,9599. Tanpa augmentasi model memang menghafal train set (akurasi 100%), tetapi generalisasinya tidak lebih buruk. Ada beberapa dugaan penyebabnya. Pertama, fitur pretrained, learning rate kecil, weight decay, dan early stopping kemungkinan sudah cukup kuat sebagai regularisasi. Kedua, augmentasi yang dipakai tergolong ringan. Ketiga, validasi hanya 300 citra sehingga selisih 1 poin setara 3 citra dan masih bisa dianggap *noise*. Augmentasi juga menambah waktu pelatihan, yaitu 13,51 vs 9,29 detik/epoch (+45%), kemungkinan karena pemrosesan CPU pada *data loader* (belum diprofilkan). Kesimpulan ini hanya berlaku untuk satu seed dan kondisi B3.

## C3. Failure Analysis (Analisis Kasus Misklasifikasi)

Model terbaik berdasarkan validasi adalah B5 (EfficientNet-B0) dengan 7 salah prediksi dari 300 citra test. Ketujuhnya ditampilkan pada Gambar 2 dan diurutkan dari *confidence* tertinggi.




**Tabel 3.** Hipotesis penyebab kesalahan

| No | Ground truth | Prediksi (conf.) | Hipotesis penyebab |
|---|---|---|---|
| 1 | bengal | abyssinian (1,00) | Bulu oranye-cokelat dan pola *rosette* tidak terlihat, cahaya kemerahan, serta kualitas citra rendah. Bisa jadi karena ambiguitas visual atau label yang sulit. Model sangat yakin meski salah. |
| 2 | siamese | birman (0,85) | Anak kucing kecil di dalam keranjang. Objeknya hanya mengisi sebagian kecil frame, latar putih-merah mendominasi, dan sebagian tubuh tertutup keranjang. |
| 3 | siamese | birman (0,75) | Bulu relatif panjang dan lebat dengan *mask* gelap. Kedua ras sama-sama berpola *colorpoint* dan bermata biru sehingga sulit dibedakan. |
| 4 | abyssinian | bengal (0,75) | Pose ekstrem (berbaring terbalik), kaki putih terlihat, dan latar berupa kotak bertuliskan teks. Sudut pengambilan gambar tidak lazim. |
| 5 | birman | siamese (0,55) | Ada bingkai hitam di sekeliling citra. Wajah gelap bermata biru, sedangkan ciri khas Birman (kaki putih seperti "sarung tangan") tidak terlihat. |
| 6 | birman | siamese (0,52) | *Close-up* wajah, sehingga ciri pembeda Birman tidak tampak dan yang terlihat hanya *mask* gelap dan mata biru yang mirip Siamese. |
| 7 | shiba inu | beagle (0,43) | Anjing tricolor (putih, cokelat, hitam) yang lebih mirip ras lain (misalnya Australian Shepherd). Diduga ada *label noise* dan perlu diperiksa manual. Pola tricolor memicu prediksi beagle. |

**Pola:** 4 dari 7 kesalahan merupakan konfusi siamese ↔ birman dan 6 dari 7 terjadi pada kucing. Hal ini sesuai dengan laporan per kelas, yaitu F1 birman dan siamese paling rendah (masing-masing 0,933). Empat kesalahan memiliki *confidence* ≥ 0,75, jadi *confidence* saja tidak cukup untuk mendeteksi semua kesalahan.

## C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Untuk skenario dengan ±1.400 citra latih, 10 kelas, dan domain yang dekat dengan ImageNet, rekomendasi saya sebagai berikut:

- **Mulai dari feature extraction (B2).** Parameter yang dilatih hanya 5.130, akurasi test 97%, dan kurvanya stabil. Backbone bisa dipakai bersama untuk beberapa tugas sehingga yang perlu disimpan hanya head-nya.
- **Pertimbangkan fine-tuning bertahap (B3)** jika domain data jauh berbeda dari ImageNet atau data bertambah. Pada data kami B3 tidak terbukti lebih baik pada test set. Differential learning rate, BatchNorm beku, dan early stopping sebaiknya tetap dipakai.
- **EfficientNet-B0 (B5)** memberi hasil terbaik (F1 test 0,9767) dengan total parameter 2,8× lebih kecil (4,02 juta vs 11,18 juta) dan waktu total ±15% lebih singkat dari B3. Tetapi waktu per epoch justru lebih lama (14,4 vs 13,5 detik), jadi hemat waktunya berasal dari early stopping yang berhenti lebih awal, bukan dari komputasi per epoch. Cocok digunakan jika ukuran model menjadi kendala.
- **Augmentasi ringan bersifat opsional.** Pada percobaan ini tidak ada manfaat yang terukur, tetapi biaya CPU bertambah.
- **Operasional:** kesalahan model cenderung ambigu secara visual, sehingga perlu ambang *confidence* dan *human review*. Pada kasus kami, 3 dari 7 kesalahan memiliki *confidence* < 0,6, tetapi 4 lainnya tidak tertangkap oleh ambang tersebut.

**Limitasi**

- Hanya memakai **satu seed (42) dan satu split**. Dengan 300 citra test, 1 citra = 0,33 poin dan galatnya ±2 poin, sehingga peringkat B2, B3, B4, dan B5 tidak signifikan secara statistik.
- Hanya **10 kelas** dan semuanya beririsan dengan kelas ImageNet, sehingga hasil transfer learning cenderung optimistis.
- B1 dihentikan early stopping sebelum benar-benar konvergen (akurasi train bersih 61,5%), jadi baseline-nya pesimistis.
- Hyperparameter tidak di-*tuning* (hanya satu konfigurasi learning rate dan weight decay) dan B4 hanya diuji pada B3.
- B5 mengubah dua faktor sekaligus, yaitu arsitektur dan blok yang dibuka (features[7:9], yang hanya mirip dengan layer4).
- Waktu pelatihan diukur pada GPU Colab bersama dengan num_workers=2, sehingga bisa *noisy* dan terbatas oleh CPU.
- Akurasi val B3, B4, dan B5 lebih tinggi daripada test (selisih 2–3 poin), kemungkinan karena checkpoint dipilih berdasarkan val loss.

## Pernyataan Penggunaan AI (AI Disclosure Statement)

**Nama model/alat AI:** Claude (Anthropic).

**Ruang lingkup bantuan:** membantu merapikan struktur dan tata bahasa draf laporan Bagian C, menyesuaikan pilihan kata, memformat tabel, serta memeriksa konsistensi hitungan turunan pada laporan. Eksperimen, kode, dan seluruh angka hasil berasal dari eksekusi notebook saya sendiri.

**Cara verifikasi mandiri:** Setiap hasil dalam percobaan dijalankan lalu dicek ulang apakah ada error dalam kode, serta penjelasan divalidasi dengan materi PPT yang berkaitan.